



UTEM

UNIVERSIDAD
TECNOLÓGICA
METROPOLITANA

del Estado de Chile

Universidad Tecnológica Metropolitana

Metodología de la Investigación en Ciencia de Datos

Contribución predictiva de variables psicológicas, académicas y conductuales al burnout académico en estudiantes universitarios

Modelos explicables de Ciencia de Datos y dataset prospectivo

Estudiante: Felipe Martínez González

Carrera: Ciencia de Datos

Asignatura: Metodología de la Investigación en Ciencia de Datos

Institución: Universidad Tecnológica Metropolitana

Fecha: 11 de julio de 2026

1. Resumen y palabras clave

El burnout académico constituye una problemática relevante en educación superior por su relación con agotamiento, desenganche, deterioro del bienestar y dificultades de permanencia estudiantil. La evidencia reciente identifica factores psicológicos, académicos y conductuales asociados al fenómeno; sin embargo, existe una integración limitada entre modelamiento predictivo, comparación de grupos de variables, explicabilidad y evaluación de la estabilidad de las interpretaciones. El objetivo de esta investigación es analizar la contribución predictiva de variables psicológicas, académicas y conductuales al nivel de burnout académico en estudiantes de pregrado de la Universidad Tecnológica Metropolitana mediante modelos explicables de Ciencia de Datos.

Se propone un estudio cuantitativo, observacional, prospectivo, transversal, predictivo y comparativo. El proyecto contempla la construcción futura de un dataset primario mediante una encuesta digital anónima. La variable objetivo será una medición continua de burnout académico obtenida con un instrumento validado y autorizado para uso en estudiantes. Como predictores se considerarán variables de estrés, engagement, autoeficacia, apoyo social, rendimiento, carga académica, sueño, estudio, actividad física y uso de tecnología. Se comparará una regresión Elastic Net con XGBoost. La contribución de las variables se examinará mediante coeficientes estandarizados, valores SHAP, importancia por permutación y análisis de ablación por dimensiones. La evaluación utilizará validación cruzada anidada y métricas de error predictivo, junto con indicadores de estabilidad de rankings y direcciones de contribución.

Se espera obtener un protocolo reproducible, un diccionario de datos, una estrategia de validación y evidencia sobre qué variables aportan información predictiva consistente. El estudio no pretende establecer causalidad ni realizar diagnósticos clínicos.

Palabras clave: burnout académico; explicabilidad; predicción; estudiantes universitarios; Ciencia de Datos.

2. Introducción, antecedentes y fundamentación del problema

2.1. Contexto y relevancia

El burnout académico se entiende como una respuesta de agotamiento asociada a demandas sostenidas del rol de estudiante. En educación superior suele expresarse mediante agotamiento, cinismo o desenganche y disminución de la eficacia académica. Su relevancia no se limita al malestar individual: también puede vincularse con menor engagement, deterioro del bienestar, dificultades de rendimiento e intención de abandono [4, 7].

La literatura reciente muestra que el fenómeno no depende de un único antecedente. Se han descrito asociaciones con actividad física, sueño, hábitos de estudio, uso de teléfonos inteligentes, bienestar psicológico y condiciones académicas e institucionales [4, 8, 9, 2]. Esta multiplicidad de factores convierte el burnout académico en un problema adecuado para Ciencia de Datos, siempre que el modelamiento no reduzca el objetivo a maximizar una métrica predictiva.

En contextos universitarios, un modelo puede alcanzar un desempeño aceptable y aun así resultar poco útil si no permite comprender qué información utiliza, si sus conclusiones cambian fuertemente entre muestras o si confunde asociación predictiva con causalidad. La explicabilidad, por tanto, debe evaluarse como parte del diseño y no agregarse únicamente como una visualización posterior.

2.2. Antecedentes metodológicos

Los estudios revisados utilizan enfoques diversos. Cuevas Caravaca et al. [4] aplican análisis correlacional y regresión múltiple para estudiar burnout y agotamiento emocional. Mudło-Głagolska y Larionow [7] incorporan análisis longitudinal y redes para examinar relaciones entre pasión por estudiar, salud mental y burnout. Rodríguez Muñoz y Antino [9] emplean un diseño de diario y

análisis multinivel para analizar el uso del teléfono móvil, engagement y agotamiento. Rodrigues Matos et al. [8] relacionan hábitos de estudio, sueño y salud mental mediante análisis transversal y de redes.

Otros trabajos aportan evidencia complementaria. Bojorque et al. [2] muestran el potencial de la analítica institucional para estudiar factores de estrés en educación superior, mientras que Alluri et al. [1] incorporan restricciones de equidad en clustering de salud mental estudiantil. Estos avances son relevantes, pero no resuelven de forma integrada la identificación, dirección y estabilidad de las contribuciones predictivas de variables psicológicas, académicas y conductuales dentro de un mismo diseño.

2.3. Problema de investigación

El problema no consiste únicamente en predecir un puntaje de burnout. El desafío metodológico es determinar qué variables y dimensiones aportan información al modelo, cómo cambia la predicción ante sus valores y si las conclusiones se mantienen entre algoritmos y particiones de datos. Una importancia alta obtenida en una sola ejecución puede ser inestable, redundante por correlación o dependiente del modelo seleccionado.

También existe un riesgo conceptual. En datos observacionales, los métodos de explicabilidad describen el comportamiento del modelo; no demuestran que una variable cause burnout. Por ello, la investigación utilizará expresiones como *contribución predictiva*, *asociación* o *dirección de la estimación*, evitando lenguaje causal.

2.4. Brecha y justificación

La brecha identificada es la integración limitada entre cuatro componentes: modelamiento predictivo, comparación de grupos de variables, explicabilidad y estabilidad de las interpretaciones. La literatura permite proponer variables plausibles, pero no consolida un protocolo que compare simultáneamente dimensiones psicológicas, académicas y conductuales, mida cuánto se deteriora el desempeño al retirar cada grupo y verifique si los rankings de importancia son consistentes.

El proyecto se justifica en tres niveles. Primero, aporta una estructura metodológica para construir un dataset específico y documentado. Segundo, combina un modelo lineal regularizado y uno no lineal, lo que permite contrastar explicaciones bajo supuestos distintos. Tercero, incorpora evaluación de estabilidad, aspecto necesario antes de utilizar los resultados para orientar levantamientos de información o intervenciones preventivas. El producto esperado es una metodología reproducible, no un instrumento clínico ni un sistema automático de decisión.

3. Pregunta de investigación e hipótesis

3.1. Pregunta de investigación

¿Qué variables psicológicas, académicas y conductuales presentan una mayor contribución predictiva al nivel de burnout académico en estudiantes de pregrado de la Universidad Tecnológica Metropolitana, y qué tan estables son dichas contribuciones entre un modelo Elastic Net y un modelo XGBoost?

3.2. Hipótesis de investigación

Las variables psicológicas y conductuales presentarán una contribución predictiva mayor y más estable al nivel de burnout académico que las variables académicas consideradas de manera aislada. Asimismo, un modelo que integre las tres dimensiones presentará menor error predictivo que los modelos contruidos con una sola dimensión.

3.3. Hipótesis nula

No existirán diferencias relevantes en la contribución predictiva de las dimensiones psicológica, académica y conductual, y el modelo integrado no presentará un desempeño superior a las configuraciones construidas con una sola dimensión.

La hipótesis se contrastará mediante diferencias de desempeño entre configuraciones, análisis de ablación, distribución de importancias entre particiones y concordancia de rankings. No se considerará respaldada únicamente porque una variable aparezca en el primer lugar de una ejecución.

4. Objetivos

4.1. Objetivo general

Analizar la contribución predictiva de variables psicológicas, académicas y conductuales al nivel de burnout académico en estudiantes de pregrado de la Universidad Tecnológica Metropolitana mediante modelos explicables de Ciencia de Datos.

4.2. Objetivos específicos

1. Diseñar y construir un dataset prospectivo que integre una medición validada de burnout académico con variables psicológicas, académicas, conductuales y sociodemográficas de control.
2. Desarrollar y evaluar modelos Elastic Net y XGBoost para estimar el nivel de burnout académico.
3. Estimar e interpretar la magnitud y dirección de la contribución de las variables mediante coeficientes estandarizados, valores SHAP e importancia por permutación.
4. Comparar la contribución de los grupos de variables mediante análisis de ablación y evaluar la estabilidad de las variables más relevantes entre modelos y particiones de validación.

5. Diseño experimental, metodología o métodos

5.1. Tipo de estudio y diseño general

La investigación tendrá enfoque cuantitativo y computacional. Será observacional porque no manipulará las variables; prospectiva porque el dataset se recolectará después de aprobar el protocolo; transversal porque cada estudiante será medido inicialmente en un único momento; predictiva porque estimará un outcome de burnout; y comparativa porque contrastará modelos y configuraciones de variables.

El diseño no permitirá establecer causalidad ni evolución temporal. Una extensión longitudinal podrá considerarse como proyección futura.

5.2. Esquematización metodológica




Figura 1: Pipeline metodológico propuesto.

5.3. Datos, fuentes y criterios de selección

Fuente y unidad de análisis. Se propone construir un dataset primario mediante una encuesta digital anónima. La unidad de análisis será cada estudiante de pregrado participante. La población inicial se delimitará a estudiantes con matrícula vigente en la Universidad Tecnológica Metropolitana.

Tamaño esperado. Se proyecta una muestra inicial de 300 a 400 registros. Esta cifra es preliminar y deberá justificarse antes de ejecutar el estudio mediante análisis de potencia, curvas de aprendizaje, número final de predictores y precisión requerida para las métricas. No se asumirá que dicho rango garantiza representatividad.

Variable objetivo. El outcome principal será una medición continua de burnout académico obtenida mediante una escala validada para estudiantes y autorizada para su aplicación. El MBI-SS se considerará como candidato por su uso en literatura universitaria [4], pero su selección dependerá de licencia, adaptación lingüística, reglas de puntuación y pertinencia para la población. Si el instrumento reporta dimensiones sin un puntaje total validado, cada dimensión se modelará por separado. Solo se realizará una clasificación de riesgo si existen puntos de corte validados.

Predictores. Se considerarán variables psicológicas, académicas, conductuales y de control. Los ítems o dimensiones utilizados para construir la variable objetivo no se incluirán como predictores del mismo outcome, porque ello produciría fuga de información.

Cuadro 1: Diccionario preliminar resumido.

Dimensión	Variables preliminares	Fuente prevista y observaciones
Psicológica	Estrés percibido, engagement, autoeficacia, apoyo social	Escala validada independiente del instrumento de burnout.
Académica	Promedio, carga académica, asignaturas reprobadas, año de carrera	Autorreporte estructurado o registros autorizados; se documentará la escala y periodo.
Conductual	Horas y calidad de sueño, horas de estudio, actividad física, uso de smartphone	Autorreporte con periodos de referencia definidos; sin interpretar como evaluación clínica.
Control	Edad, género, situación laboral, responsabilidades familiares	Se utilizarán para ajuste y análisis de representación, no para decisiones individuales.

Criterios de inclusión. Matrícula vigente, pertenencia a la población definida, consentimiento informado y respuesta suficiente del instrumento principal. **Criterios de exclusión.** Ausencia de consentimiento, duplicados, registros fuera de la población y cuestionarios insuficientes según reglas

fijadas antes del análisis. Los valores extremos no se eliminarán automáticamente; se distinguirán errores de captura de observaciones plausibles.

5.4. Procedimientos y etapas metodológicas

1. **Diseño del instrumento.** Selección de escalas, redacción de preguntas académicas y conductuales, revisión de licencia, elaboración del consentimiento y definición del diccionario.
2. **Prueba piloto.** Evaluación de comprensión, duración, consistencia de rangos y funcionamiento del formulario. Los cambios se documentarán antes de la aplicación definitiva.
3. **Recolección y resguardo.** Difusión por canales autorizados, participación voluntaria, ausencia de identificadores directos, asignación de códigos aleatorios y almacenamiento con acceso restringido.
4. **Control de calidad.** Detección de duplicados, evaluación de faltantes, consistencia de respuestas, revisión de rangos y registro transparente de exclusiones.
5. **Análisis exploratorio.** Distribuciones, estadísticos descriptivos, patrones de faltantes, correlaciones, colinealidad y representación de subgrupos.
6. **Preprocesamiento.** Imputación, codificación y estandarización dentro de cada partición de entrenamiento. No se ajustará el preprocesamiento usando información del fold de evaluación.
7. **Modelamiento, explicación y estabilidad.** Entrenamiento de los modelos, evaluación de desempeño, generación de explicaciones y comparación entre particiones y configuraciones.

Cuadro 2: Relación entre objetivos y metodología.

Objetivo	Procedimientos	Métodos	Resultado esperado
OE1	Instrumentos, piloto, consentimiento, recolección y calidad	Encuesta prospectiva, análisis descriptivo, diccionario	Dataset documentado y apto para modelamiento.
OE2	Pipelines, ajuste y comparación	Elastic Net, XGBoost, validación cruzada anidada	Métricas predictivas con estimación de incertidumbre.
OE3	Extracción y contraste de importancias	Coeficientes, SHAP y permutación	Magnitud y dirección de contribuciones.
OE4	Modelos parciales, eliminación de grupos y repetición	Ablación, top- k , correlación de rankings	Variables y dimensiones con contribución estable.

5.5. Métodos de análisis, modelamiento y evaluación

Elastic Net. Se utilizará como baseline interpretable. Combina penalizaciones L_1 y L_2 , favorece regularización y puede manejar grupos de predictores correlacionados [10]. Los predictores numéricos se estandarizarán dentro del pipeline. Se analizarán signo, magnitud y variabilidad de los coeficientes, reconociendo que la regularización modifica su interpretación.

XGBoost. Se utilizará como contraste no lineal, por su capacidad para representar interacciones y relaciones complejas mediante boosting de árboles [3]. No se asumirá que será superior; deberá demostrar mejor desempeño y explicaciones suficientemente estables.

Explicabilidad. Los valores SHAP se utilizarán para explicaciones globales y locales del modelo, asignando contribuciones a variables para predicciones específicas [6]. La importancia por permutación estimará cuánto disminuye el desempeño al alterar una variable; se interpretará como dependencia del modelo, no como efecto causal [5]. Debido a la correlación entre predictores, los resultados se contrastarán entre métodos y se evitarán conclusiones basadas en una única medida.

Ablación. Se entrenarán configuraciones con todas las dimensiones, con cada dimensión por separado

y retirando una dimensión a la vez. El cambio en MAE, RMSE y R^2 permitirá estimar el aporte incremental de cada grupo.

Validación. Se propone validación cruzada anidada de cinco folds. El ciclo interno se utilizará para hiperparámetros y el externo para estimación de desempeño. Cuando el tamaño muestral lo permita, el proceso se repetirá con distintas semillas. Se reportarán media, desviación estándar e intervalos de confianza.

Métricas. Para outcome continuo se usarán MAE, RMSE y R^2 . Si se incorpora una clasificación secundaria con puntos de corte validados, se agregarán ROC-AUC, PR-AUC, sensibilidad, precisión, F1, especificidad y calibración.

Estabilidad. Para cada variable se calcularán ranking medio, frecuencia de aparición en el top-5, dirección predominante, dispersión de coeficientes o SHAP y correlación de rankings entre folds. Se examinará la concordancia entre Elastic Net, SHAP y permutación. Una variable no se considerará robusta por aparecer una vez entre las principales.

5.6. Aspectos críticos, limitaciones y consideraciones éticas

Las principales amenazas metodológicas serán sesgo de autoselección, error de autorreporte, datos faltantes, colinealidad, tamaño muestral insuficiente, representación desigual de subgrupos y posible inestabilidad de importancias. El diseño transversal impedirá establecer causalidad o dirección temporal. Además, SHAP y la permutación explican la dependencia de un modelo respecto de sus entradas, no mecanismos psicológicos reales.

La recolección exigirá consentimiento informado, participación voluntaria, anonimización, almacenamiento seguro, acceso restringido y aprobación institucional antes de utilizar datos sensibles. No se recopilarán nombres, correos institucionales ni identificadores académicos en el dataset analítico. El modelo no se utilizará para diagnóstico clínico, sanciones, negación de beneficios ni decisiones académicas automáticas. Si el tamaño de los subgrupos lo permite, se evaluarán diferencias de error para detectar riesgos de inequidad.

6. Resultados esperados, contribución y alcance

Se espera construir un dataset prospectivo documentado, acompañado de un diccionario de datos, reglas de calidad y un pipeline reproducible. También se espera obtener una comparación válida entre Elastic Net y XGBoost, junto con estimaciones de contribución de variables y dimensiones bajo métodos complementarios.

La hipótesis anticipa que variables psicológicas y conductuales podrían aportar más información que las académicas aisladas, especialmente aquellas vinculadas con estrés, engagement y sueño, de acuerdo con la literatura revisada [4, 7, 8]. Esta expectativa no se presentará como resultado: deberá ser contrastada con los datos futuros.

La contribución científica y metodológica radica en integrar predicción, explicabilidad, ablación y estabilidad. La contribución aplicada consiste en ofrecer criterios para priorizar variables en futuros levantamientos de información y apoyar investigaciones preventivas. El alcance inicial estará restringido a la institución y periodo de recolección; cualquier generalización a otras universidades requerirá validación externa.

Entre las proyecciones futuras se encuentran una segunda medición longitudinal, incorporación de registros académicos autorizados, validación externa y evaluación de la utilidad del modelo con profesionales responsables del bienestar estudiantil.

7. Declaración de uso de inteligencia artificial

1. En etapas previas del trabajo se utilizó Gemini, modelo **Gemini 2.5 Pro**, el 3 de mayo de 2026, como apoyo para la formulación del problema de investigación en el contexto de la Entrega de la Unidad 2. El prompt principal utilizado fue:

“Actúa como asistente de investigación en Ciencia de Datos. Ayúdame a formular y delimitar el problema de investigación sobre burnout académico en estudiantes universitarios, considerando su relevancia, el contexto disciplinar y una posible brecha en la literatura.”

Las propuestas generadas fueron contrastadas con la literatura revisada y ajustadas por el estudiante antes de integrarlas al planteamiento del problema.

2. Se utilizó ChatGPT, modelo **GPT-5.6 Thinking**, el 11 de julio de 2026, como apoyo para revisar la coherencia metodológica, reformular la pregunta, hipótesis y objetivos, organizar el diseño experimental, redactar una versión del informe en $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ y desarrollar la aplicación Streamlit. El prompt principal sintetizado fue:

“Actúa como experto en metodología de investigación en Ciencia de Datos. Reformula el proyecto sobre burnout académico para centrarlo en la contribución predictiva de variables psicológicas, académicas y conductuales. Alinea problema, brecha, pregunta, hipótesis, objetivos y metodología con la rúbrica final. No inventes resultados ni atribuyas causalidad. Genera un informe en LaTeX y una app Streamlit ejecutable.”

Las propuestas fueron revisadas respecto de la rúbrica, el informe previo y las referencias citadas. El código fue compilado y la aplicación fue sometida a revisión de sintaxis y ejecución

3. Se utilizó Claude, modelo **Claude Sonnet 5**, el 11 de julio de 2026, como apoyo para revisar la coherencia metodológica del informe, mejorar la redacción y organización del documento en $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$, y depurar y perfeccionar la aplicación Streamlit. El prompt principal utilizado fue:

“Actúa como experto en metodología de investigación en Ciencia de Datos. Revisa el informe y la aplicación Streamlit adjuntos, e identifica errores de coherencia, redacción o implementación. Propón mejoras concretas sin inventar resultados ni atribuir causalidad, y sin modificar el enfoque original del proyecto.”

Las sugerencias fueron revisadas por el estudiante, contrastadas con la rúbrica y las referencias citadas, y modificadas antes de incorporarlas a la versión final.

Referencias

- [1] P. Alluri, Z. Chen, T. Thesen, N. C. Jacobson y W. J. Marrero, “Fairness-aware K-means clustering in digital mental health for higher education students: A generalizable framework for equitable clustering,” *JAMIA Open*, vol. 9, n.º 1, art. ooaf174, 2026. doi: 10.1093/jamia-open/ooaf174.
- [2] R. Bojorque, F. Moscoso, F. Pesántez y Á. Flores, “Stress factors in higher education: A data analysis case,” *Data*, vol. 10, art. 22, 2025. doi: 10.3390/data10020022.
- [3] T. Chen y C. Guestrin, “XGBoost: A scalable tree boosting system,” en *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794. doi: 10.1145/2939672.2939785.
- [4] E. Cuevas Caravaca, E. J. Garcés de los Fayos Ruiz, E. I. Sánchez Romero y J. L. López Morales, “Academic burnout and emotional exhaustion among university students: The role of physical exercise,” *SPORT TK-EuroAmerican Journal of Sport Sciences*, vol. 14, art. 99, 2025. doi: 10.6018/sportk.583751.
- [5] A. Fisher, C. Rudin y F. Dominici, “All models are wrong, but many are useful: Learning a variable’s importance by studying an entire class of prediction models simultaneously,” *Journal of Machine Learning Research*, vol. 20, n.º 177, pp. 1–81, 2019.
- [6] S. M. Lundberg y S.-I. Lee, “A unified approach to interpreting model predictions,” en *Advances in Neural Information Processing Systems 30*, 2017, pp. 4765–4774.
- [7] K. Mudło-Głagolska y P. Larionow, “Passion for studying and its relationships with academic burnout and mental health: Longitudinal insights into sustainable students’ functioning,” *Sustainability*, vol. 17, art. 9852, 2025. doi: 10.3390/su17219852.
- [8] F. Rodrigues Matos, R. M. Malavasi y A. L. De Andrade, “Relações entre burnout estudantil, saúde mental, hábitos de estudo e sono: Um estudo transversal,” *Pensando Psicologia*, vol. 20, n.º 1, pp. 1–19, 2024. doi: 10.16925/2382-3984.2024.01.01.
- [9] A. Rodríguez Muñoz y M. Antino, “El uso del teléfono móvil en clase y su efecto sobre el engagement académico y el agotamiento: Un estudio de diario en estudiantes universitarios,” *European Journal of Education and Psychology*, vol. 14, n.º 1, pp. 1–10, 2021. doi: 10.32457/ejep.v14i1.1401.
- [10] H. Zou y T. Hastie, “Regularization and variable selection via the elastic net,” *Journal of the Royal Statistical Society: Series B*, vol. 67, n.º 2, pp. 301–320, 2005. doi: 10.1111/j.1467-9868.2005.00503.x.